

Bài tập lập trình

Bài 1: Lọc tần số | Bài 2: Phát hiện đặc trưng | Bài 3: Simplified SIFT

Hướng dẫn chung. Mỗi bài yêu cầu cài đặt từ đầu — không dùng hàm có sẵn thực hiện chức năng chính (ví dụ không gọi `scipy.signal.convolve` cho phần lọc, không gọi `cv2.cornerHarris` cho phần Harris). Được phép dùng `numpy` cho đại số tuyến tính cơ bản và `matplotlib` để hiển thị. File nộp là notebook `.ipynb` chạy được từ đầu đến cuối, đã hiển thị kết quả trước.
Lưu ý Đây là bài tập nhóm. Chỉ cần 1 thành viên đại diện nộp bài.

1 Bài 1 — Lọc trong miền tần số

1.1 Nền tảng toán học

1.1.1 Biến đổi Fourier rời rạc 2D

Cho ảnh xám $f \in \mathbb{R}^{M \times N}$, biến đổi Fourier rời rạc 2D (DFT 2D):

$$F(u, v) = \sum_{x=0}^{M-1} \sum_{y=0}^{N-1} f(x, y) e^{-j2\pi(\frac{ux}{M} + \frac{vy}{N})}, \quad u = 0, \dots, M-1, v = 0, \dots, N-1 \quad (1)$$

Biến đổi ngược (IDFT):

$$f(x, y) = \frac{1}{MN} \sum_{u=0}^{M-1} \sum_{v=0}^{N-1} F(u, v) e^{j2\pi(\frac{ux}{M} + \frac{vy}{N})} \quad (2)$$

Định lý tích chập. Nếu $g = f * h$ (tích chập không gian), thì $G(u, v) = F(u, v) \cdot H(u, v)$. Để lọc ảnh trong miền tần số:

$$g(x, y) = \mathcal{F}^{-1}\{F(u, v) \cdot H(u, v)\}$$

trong đó $H(u, v)$ là hàm truyền (transfer function) của bộ lọc.

1.1.2 Tần số trong ảnh rời rạc

Sau `fftshift`, tần số $(0, 0)$ nằm ở trung tâm. Khoảng cách từ tâm đến điểm (u, v) :

$$D(u, v) = \sqrt{\left(u - \frac{M}{2}\right)^2 + \left(v - \frac{N}{2}\right)^2} \quad (3)$$

Tất cả các bộ lọc đối xứng tròn đều được biểu diễn qua $D(u, v)$.

1.2 Các bộ lọc cần cài đặt

1.2.1 Lọc thấp và cao lý tưởng (Ideal LP/HP)

$$H_{\text{LP}}^{\text{ideal}}(u, v) = \begin{cases} 1 & D(u, v) \leq D_0 \\ 0 & D(u, v) > D_0 \end{cases} \quad H_{\text{HP}}^{\text{ideal}}(u, v) = 1 - H_{\text{LP}}^{\text{ideal}}(u, v) \quad (4)$$

Tần số cắt D_0 là tham số. Lọc lý tưởng gây ra **hiện tượng Gibbs** (ringing) do tích chập với sinc 2D trong miền không gian.

1.2.2 Lọc Butterworth bậc n

$$H_{\text{LP}}^{\text{BW}}(u, v) = \frac{1}{1 + \left[\frac{D(u, v)}{D_0} \right]^{2n}} \quad H_{\text{HP}}^{\text{BW}}(u, v) = \frac{1}{1 + \left[\frac{D_0}{D(u, v)} \right]^{2n}} \quad (5)$$

Tham số: tần số cắt D_0 và bậc n . Tại $D(u, v) = D_0$: $H_{\text{LP}}^{\text{BW}} = 0.5$ với mọi n . Khi $n \rightarrow \infty$, Butterworth tiệm cận lọc lý tưởng.

Nhận xét. Butterworth không có sự cắt đột ngột nên không gây ringing như lọc lý tưởng. Đây là lý do thường dùng Butterworth thay vì lọc lý tưởng trong thực tế.

1.2.3 Lọc băng thông (Band-pass)

$$H_{\text{BP}}(u, v) = H_{\text{LP}}(u, v; D_{\text{high}}) - H_{\text{LP}}(u, v; D_{\text{low}}) \quad (6)$$

với $D_{\text{low}} < D_{\text{high}}$. Chỉ cho qua tần số trong dải $[D_{\text{low}}, D_{\text{high}}]$. Dùng hàm truyền Butterworth để tránh ringing.

1.2.4 Lọc notch

Lọc notch chặn một tần số cụ thể (u_0, v_0) và điểm đối xứng $(M/2 - u_0, N/2 - v_0)$ (do tính đối xứng Hermitian của DFT ảnh thực):

$$D_k(u, v) = \sqrt{(u - u_k)^2 + (v - v_k)^2}, \quad k = 1, 2 \quad (7)$$

$$H_{\text{notch}}(u, v) = \prod_{k=1}^2 \frac{1}{1 + \left[\frac{D_0}{D_k(u, v) + \epsilon} \right]^{2n}} \quad (8)$$

trong đó ϵ nhỏ để tránh chia cho không tại tâm notch.

Lưu ý cài đặt. Khi $D_k(u, v) = 0$ (đúng tại tâm notch), mẫu số bằng không. Xử lý bằng cách thêm $\epsilon = 10^{-6}$ vào D_k .

1.3 Quy trình lọc tổng quát

Với bất kỳ bộ lọc $H(u, v)$ nào, quy trình lọc ảnh gồm bốn bước:

1. Tính DFT: $F = \text{fft2}(f)$, sau đó $F_s = \text{fftshift}(F)$
2. Xây dựng mask $H(u, v)$ kích thước $M \times N$ theo công thức tương ứng
3. Nhân điểm-điểm: $G_s = F_s \cdot H$
4. Tái tạo: $g = \text{Re}[\text{ifft2}(\text{ifftshift}(G_s))]$

`ifftshift` phải được gọi trước `ifft2` để hoàn tác bước `fftshift`. Thứ tự sai sẽ gây artifact.

1.4 Yêu cầu cài đặt

- 1.1. **Cài đặt DFT 2D và IDFT 2D từ đầu** theo công thức (1)-(2). Kiểm chứng bằng `np.allclose` so với `np.fft.fft2`.
- 1.2. **Cài đặt bốn bộ lọc:** Ideal LP/HP, Butterworth LP/HP bậc n , Band-pass Butterworth, Notch Butterworth.
- 1.3. **Thí nghiệm:** với ảnh thực hoặc ảnh tổng hợp, hiển thị phổ biên độ (log scale) và kết quả lọc với các tham số khác nhau. Giải thích hiện tượng Gibbs và so sánh Ideal vs Butterworth.

2 Bài 2 — Phát hiện đặc trưng

2.1 Nền tảng toán học

2.1.1 Structure Tensor

Cho ảnh f , hàm $E(u, v)$ đo sự thay đổi cường độ khi dịch cửa sổ (u, v) :

$$E(u, v) \approx \begin{bmatrix} u & v \end{bmatrix} M \begin{bmatrix} u \\ v \end{bmatrix} \quad (9)$$

Ma trận M là **structure tensor**:

$$M = \sum_{(x,y) \in W} w(x, y) \begin{bmatrix} f_x^2 & f_x f_y \\ f_x f_y & f_y^2 \end{bmatrix} \quad (10)$$

trong đó f_x, f_y là đạo hàm Sobel, $w(x, y)$ là cửa sổ Gaussian.

Phân loại vùng ảnh theo eigenvalue $\lambda_1 \geq \lambda_2$ của M :

Điều kiện	Vùng	Ý nghĩa
$\lambda_1 \approx \lambda_2 \approx 0$	Phẳng	Không có thay đổi cường độ
$\lambda_1 \gg \lambda_2 \approx 0$	Cạnh	Thay đổi một chiều
$\lambda_1 \approx \lambda_2 \gg 0$	Góc	Thay đổi mọi chiều

2.1.2 Harris Corner Detector

Thay vì tính eigenvalue trực tiếp, Harris dùng hàm phản hồi:

$$R = \det(M) - k \cdot [\text{tr}(M)]^2 = \lambda_1 \lambda_2 - k(\lambda_1 + \lambda_2)^2 \quad (11)$$

Với $\det(M) = f_x^2 f_y^2 - (f_x f_y)^2$ và $\text{tr}(M) = f_x^2 + f_y^2$.

Quy tắc phân loại: $R \gg 0$ là góc; $R \ll 0$ là cạnh; $|R| \approx 0$ là phẳng. Tham số $k \in [0.04, 0.06]$, thường chọn $k = 0.05$.

Quy trình Harris đầy đủ:

1. Tính $f_x = K_x * f$, $f_y = K_y * f$ bằng Sobel 3×3
2. Tính $A = f_x^2$, $B = f_x f_y$, $C = f_y^2$
3. Làm mịn: $\bar{A} = G_\sigma * A$, $\bar{B} = G_\sigma * B$, $\bar{C} = G_\sigma * C$
4. Tính $R = \bar{A}\bar{C} - \bar{B}^2 - k(\bar{A} + \bar{C})^2$
5. Non-Maximum Suppression (NMS) trong lân cận $w \times w$
6. Áp ngưỡng: giữ lại pixel với $R > T$

2.1.3 Harris-Laplace

Harris-Laplace (Mikolajczyk & Schmid, 2004) kết hợp Harris với phân tích thang đo:

$$\sigma^* = \arg \max_{\sigma} |\sigma^2 \nabla^2 L(\mathbf{x}, \sigma)| \quad (12)$$

trong đó $\nabla^2 L(\mathbf{x}, \sigma)$ là Laplacian của ảnh blur tại thang σ .

Xấp xỉ LoG bằng DoG:

$$\sigma^2 \nabla^2 L(\mathbf{x}, \sigma) \approx \frac{L(\mathbf{x}, k\sigma) - L(\mathbf{x}, \sigma)}{k - 1} \quad (13)$$

Quy trình Harris-Laplace:

1. Xây dựng scale space: $L_i = G_{\sigma_i} * f$ cho dãy $\sigma_0 < \sigma_1 < \dots$
2. Tại mỗi thang σ_i : tính R_{σ_i} và tìm ứng viên keypoint ($R_{\sigma_i} > T_R$)
3. Với mỗi ứng viên $(\mathbf{x}, \sigma_i)$: tìm $\sigma^* = \arg \max_{\sigma} |\text{DoG}(\mathbf{x}, \sigma)|$
4. Giữ lại nếu σ^* là cực đại cục bộ trong không gian thang đo
5. NMS trong không gian 2D tại thang σ^*

2.1.4 FAST

FAST (Rosten & Drummond, 2006): pixel p là góc nếu tồn tại cung $n = 12$ pixel liên tiếp trên vòng tròn Bresenham bán kính 3 (16 pixel) sao cho:

$$I_i > I_p + t \quad (\text{tất cả sáng hơn}) \quad (14)$$

$$I_i < I_p - t \quad (\text{tất cả tối hơn}) \quad (15)$$

16 offset vòng tròn Bresenham:

(0, 3), (1, 3), (2, 2), (3, 1), (3, 0), (3, -1), (2, -2), (1, -3), (0, -3), (-1, -3), (-2, -2), (-3, -1), (-3, 0), (-3, 1), (-2, 2), (-1, 3), (0, 3)

Kiểm tra nhanh (early rejection): Chỉ kiểm tra 4 pixel tại vị trí 1, 5, 9, 13. Nếu ít hơn 3 pixel thoả điều kiện, loại bỏ ngay mà không cần kiểm tra 16 pixel.

2.2 Yêu cầu cài đặt

2.1. Harris chuẩn: Cài đặt theo sáu bước ở mục 2.1.2. Tham số: σ , k , ngưỡng T , kích thước NMS.

2.2. Harris-Laplace: Cài đặt theo quy trình ở mục 2.1.3 với ít nhất 5 thang đo. Được phép xấp xỉ LoG bằng DoG theo công thức (13).

2.3. FAST: Cài đặt đầy đủ bao gồm kiểm tra nhanh 4 pixel, kiểm tra đủ 16 pixel, và NMS.

2.4. So sánh: Chạy ba phương pháp trên cùng ảnh. Đo repeatability khi xoay ảnh các góc $0^\circ, 15^\circ, 30^\circ, 45^\circ$. Vẽ đồ thị và nhận xét.

3 Hướng dẫn kỹ thuật

3.1 Kernel Sobel

$$K_x = \begin{bmatrix} -1 & 0 & +1 \\ -2 & 0 & +2 \\ -1 & 0 & +1 \end{bmatrix}, \quad K_y = K_x^\top$$

Cài đặt tích chập 3×3 thủ công. Xử lý biên bằng reflect padding.

3.2 Kernel Gaussian

Kích thước $k = 2\lceil 3\sigma \rceil + 1$ (làm tròn lên số lẻ):

$$G(i, j) = \frac{1}{2\pi\sigma^2} e^{-\frac{(i-c)^2 + (j-c)^2}{2\sigma^2}}, \quad c = \lfloor k/2 \rfloor, \quad \sum_{i,j} G(i, j) = 1$$

3.3 Non-Maximum Suppression

Với bản đồ phản hồi $R(x, y)$: giữ lại pixel (x, y) nếu $R(x, y)$ là lớn nhất trong lân cận $w \times w$ và $R(x, y) > T$. Vectorise bằng `scipy.ndimage.maximum_filter`.

3.4 Kiểm chứng

- DFT: `np.allclose(my_dft2(f), np.fft.fft2(f), atol=1e-6)`
- Lọc tích chập: `np.allclose(filter_spatial, filter_freq, atol=1e-5)`
- Harris: so sánh vị trí keypoints (dùng thủ công) với `cv2.cornerHarris` để debug
- FAST: so sánh với `cv2.FastFeatureDetector_create()` để debug

Bảng ký hiệu

Ký hiệu	Ý nghĩa	Miền giá trị
$f(x, y)$	Ảnh đầu vào	$[0, 1]$ (float)
$F(u, v)$	Phổ Fourier	$\mathbb{C}$
$H(u, v)$	Hàm truyền bộ lọc	$[0, 1]$
$D(u, v)$	Khoảng cách tần số từ DC	pixel
D_0	Tần số cắt	pixel
n	Bậc lọc Butterworth	$\mathbb{Z}^+$
M	Structure tensor	$\mathbb{R}^{2 \times 2}$
λ_1, λ_2	Eigenvalue của M	$\mathbb{R}^+$
R	Hàm phản hồi Harris	$\mathbb{R}$
k	Tham số Harris	$[0.04, 0.06]$
σ	Thang đo Gaussian	pixel
t	Ngưỡng FAST	$[0, 1]$ (nếu float)
σ^*	Thang đặc trưng keypoint	pixel
θ^*	Hướng chủ đạo keypoint	$[0^\circ, 360^\circ)$
τ_c	Ngưỡng tương phản SIFT	$[0, 1]$

4 Bài 3 — Simplified SIFT

4.1 Tại sao cần SIFT? Vấn đề với Harris

Bài 2 đã cho thấy Harris phát hiện góc hiệu quả trong ảnh tĩnh. Nhưng Harris có một hạn chế nghiêm trọng: **không bất biến với thay đổi tỉ lệ**.

Xét một góc trong ảnh gốc. Khi ảnh bị thu nhỏ hai lần, cùng góc đó thu nhỏ theo nhưng cửa sổ Gaussian σ cố định của Harris vẫn giữ nguyên kích thước pixel. Từ góc độ của sổ đó, cấu trúc góc giờ quá nhỏ để nhận ra — điểm bị phân loại sai là vùng phẳng.

Scale-Invariant Feature Transform (SIFT, Lowe 2004) giải quyết vấn đề này bằng cách tìm mỗi keypoint ở đúng thang đo phù hợp với kích thước cấu trúc của nó. Ngoài ra, SIFT còn bất biến với góc quay và thay đổi ánh sáng nhờ thiết kế descriptor cẩn thận.

4.2 Tổng quan pipeline

SIFT gốc có bốn bước. Phiên bản đơn giản hoá trong bài này bỏ qua một số bước tinh chỉnh kỹ thuật nhưng giữ nguyên tất cả ý tưởng toán học cốt lõi:

Bước	Tên	Mục tiêu	Phiên bản này
1	DoG Keypoint	Bất biến thang đo	Đầy đủ
2	Lọc keypoint	Loại ứng viên yếu	Chỉ lọc tương phản
3	Gán hướng	Bất biến góc quay	Đầy đủ (không keypoint phụ)
4	Descriptor	Bất biến ánh sáng	Đơn giản hoá ($2 \times 2 \times 8$, nearest-neighbor)

Các bước bỏ qua: tinh chỉnh Taylor dưới pixel (Bước 2a), lọc cạnh bằng Hessian ratio (Bước 2c), nội suy bilinear khi lấy pixel (thay bằng nearest-neighbor), keypoint phụ từ đỉnh phụ histogram (Bước 3), chuẩn hoá L2 hai lần (chỉ một lần).

4.3 Bước 1 — Scale Space và Difference of Gaussians

4.3.1 Scale space

Scale space. Scale space tuyến tính của ảnh f là họ hàm:

$$L(x, y, \sigma) = G_{\sigma}(x, y) * f(x, y)$$

trong đó G_{σ} là Gaussian với độ lệch chuẩn σ . Tại $\sigma = 0$: $L = f$ (ảnh gốc). Khi σ tăng: chi tiết nhỏ biến mất trước, cấu trúc lớn tồn tại sau.

Gaussian là bộ lọc làm mờ duy nhất thoả mãn: (1) tuyến tính và bất biến dịch chuyển, (2) không tạo thêm cực trị khi σ tăng, (3) đối xứng. Điều kiện (2) đảm bảo cực trị trong scale space là cấu trúc thật từ ảnh gốc, không phải artifact.

Tính chất nửa nhóm:

$$G_{\sigma_1} * G_{\sigma_2} = G_{\sqrt{\sigma_1^2 + \sigma_2^2}} \quad (16)$$

Hệ quả thực tế: để đi từ $L(\sigma)$ đến $L(\sigma')$ với $\sigma' > \sigma$, chỉ cần blur thêm với $G_{\sqrt{\sigma'^2 - \sigma^2}}$ thay vì blur lại từ ảnh gốc với kernel lớn hơn.

4.3.2 Kim tự tháp Gaussian và Octave

Thay vì tính L liên tục, SIFT rời rạc hoá thành kim tự tháp. Một **octave** là nhóm ảnh blur tại cùng độ phân giải, σ tăng từ σ_0 đến $2\sigma_0$:

$$\sigma_i = \sigma_0 \cdot k^i, \quad k = 2^{1/s} \quad (17)$$

với $s = 3$ tầng hữu dụng mỗi octave. Sau s bước, σ nhân đôi ($k^s = 2$).

Mỗi octave cần $s + 3 = 6$ ảnh Gaussian để tạo $s + 2 = 5$ ảnh DoG, trong đó $s = 3$ tầng giữa được dùng để tìm cực trị (tầng đầu và cuối không có hàng xóm đủ ở cả hai phía).

Khi kết thúc một octave, ảnh được **hạ mẫu** $\times \frac{1}{2}$ để bắt đầu octave tiếp theo. Lý do: sau khi blur với $\sigma = 2\sigma_0$, mọi chi tiết nhỏ hơn $2\sigma_0$ pixel đã biến mất. Theo định lý Nyquist, những pixel đó không còn mang thông tin mới — hạ mẫu $\times \frac{1}{2}$ loại bỏ chúng mà không mất dữ liệu, đồng thời giảm chi phí tính toán 4 lần cho octave tiếp theo.

4.3.3 Difference of Gaussians

Để phát hiện blob (cấu trúc tròn), bộ lọc lý tưởng là Laplacian of Gaussian (LoG) chuẩn hoá thang đo $\sigma^2 \nabla^2 G_\sigma$. Tuy nhiên LoG tốn kém — mỗi thang cần tích chập với kernel đặc biệt.

SIFT dùng Difference of Gaussians (DoG) xấp xỉ LoG. Từ phương trình nhiệt $\frac{\partial G_\sigma}{\partial \sigma} = \sigma \nabla^2 G_\sigma$, xấp xỉ bằng sai phân:

$$D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma) \approx (k - 1) \sigma^2 \nabla^2 G_\sigma * f \quad (18)$$

DoG rẻ vì kim tự tháp Gaussian đã được tính để hạ mẫu — DoG chỉ là phép trừ hai ảnh đã có, không cần tích chập thêm.

4.3.4 Tìm cực trị trong 26 lân cận

Keypoint ứng viên là cực đại hoặc cực tiểu cục bộ của D trong không gian ba chiều (x, y, σ) . Tại mỗi pixel (x_0, y_0) trong tầng DoG giữa, so sánh $D(x_0, y_0, \sigma_0)$ với 26 lân cận:

- 8 pixel trong cùng tầng DoG
- 9 pixel trong tầng DoG phía trên (tại $k\sigma_0$)
- 9 pixel trong tầng DoG phía dưới (tại σ_0/k)

Nếu $D(x_0, y_0, \sigma_0)$ lớn hơn tất cả 26 lân cận (cực đại) hoặc nhỏ hơn tất cả (cực tiểu), đây là ứng viên keypoint với thang đặc trưng $\sigma^* = \sigma_0$.

Thang đặc trưng σ^* . Mỗi keypoint có thang đặc trưng σ^* là thang đo tại đó nó được phát hiện. σ^* cho biết kích thước tự nhiên của cấu trúc đó — cấu trúc lớn có σ^* lớn. Khi ảnh bị phóng to s lần, σ^* nhân s theo, đảm bảo descriptor luôn mô tả cùng vùng vật lý.

4.3.5 Lọc keypoint yếu (Bước 2 đơn giản hoá)

Bỏ qua tinh chỉnh Taylor (Bước 2a) và lọc cạnh bằng Hessian (Bước 2c). Chỉ áp dụng:

$$\text{Giữ lại nếu } |D(x_0, y_0, \sigma_0)| \geq \tau_c \quad (19)$$

với $\tau_c = 0.03$ (mặc định Lowe). Keypoint có $|D|$ nhỏ nằm trong vùng gradient yếu và không ổn định với nhiễu.

4.4 Bước 3 — Gán hướng chủ đạo

Mục tiêu: gán một hướng tham chiếu θ^* cho mỗi keypoint để descriptor được tính tương đối với hướng đó. Khi ảnh bị quay ϕ , θ^* tăng ϕ , descriptor vẫn nhìn về cùng hướng vật lý — bất biến góc quay.

4.4.1 Tính gradient tại thang σ^*

Tính gradient của $L(\cdot, \sigma^*)$ (ảnh đã blur tại thang đặc trưng) trong vùng lân cận bán kính $r = 4.5\sigma^*$ quanh keypoint:

$$m(x, y) = \sqrt{L_x^2 + L_y^2} \quad (20)$$

$$\theta(x, y) = \arctan2(L_y, L_x) \quad (21)$$

4.4.2 Histogram 36 bin

Xây dựng histogram hướng 36 bin (10° mỗi bin, phủ 0° – 360°). Mỗi pixel đóng góp vào bin tương ứng với trọng số bằng biên độ gradient $m(x, y)$ nhân với Gaussian tâm tại keypoint (trọng số $\sigma_w = 1.5\sigma^*$):

$$w(x, y) = m(x, y) \cdot e^{-\frac{(x-x_0)^2 + (y-y_0)^2}{2(1.5\sigma^*)^2}} \quad (22)$$

Hướng chủ đạo $\theta^* =$ hướng của bin cao nhất.

Tại sao Gaussian weighting? Pixel gần tâm keypoint đóng góp nhiều hơn pixel ở xa — phản ánh đúng mức độ liên quan của chúng với cấu trúc tại keypoint.

Phiên bản này bỏ qua: tạo keypoint phụ khi bin phụ $\geq 80\%$ đỉnh. Mỗi keypoint chỉ có một hướng duy nhất.

4.5 Bước 4 — Xây dựng Descriptor

4.5.1 Hệ tọa độ cục bộ

Descriptor được tính trong **hệ tọa độ cục bộ** riêng của từng keypoint, xác định bởi θ^* và σ^* :

- **Trục x cục bộ:** song song với θ^*
- **Trục y cục bộ:** vuông góc với θ^*
- **Đơn vị:** σ^* pixel

Pixel tại vị trí lưới cục bộ (i, j) tương ứng với pixel thực trong ảnh tại:

$$\begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x_0 \\ y_0 \end{bmatrix} + \sigma^* \cdot R_{\theta^*} \begin{bmatrix} i \\ j \end{bmatrix}, \quad R_{\theta^*} = \begin{bmatrix} \cos \theta^* & -\sin \theta^* \\ \sin \theta^* & \cos \theta^* \end{bmatrix} \quad (23)$$

Vì (x, y) không phải số nguyên, phiên bản đơn giản hoá dùng **nearest-neighbor**: làm tròn (x, y) về pixel gần nhất và lấy giá trị trực tiếp.

Tại sao hệ tọa độ cục bộ đảm bảo bất biến? Khi ảnh bị quay ϕ : θ^* tăng ϕ , ma trận R_{θ^*} xoay theo, lưới cục bộ xoay theo đúng ϕ , descriptor nhìn về cùng hướng vật lý. Khi ảnh phóng to s lần: σ^* nhân s , lưới mở rộng s lần, descriptor bao phủ cùng vùng vật lý.

4.5.2 Lưới 2×2 ô và histogram 8 bin

Phiên bản đơn giản hoá dùng lưới 2×2 thay vì 4×4 của SIFT gốc. Vùng mô tả là 8×8 pixel trong hệ toạ độ cục bộ (chia thành $2 \times 2 = 4$ ô, mỗi ô 4×4 pixel cục bộ).

1. Lấy vùng 8×8 pixel cục bộ $(i, j \in \{-4, -3, \dots, 3\})$ bằng nearest-neighbor
2. Tính gradient biên độ m và hướng θ tại từng pixel (từ L_{σ^*})
3. Hướng tương đối: $\theta_{rel} = (\theta - \theta^*) \bmod 360^\circ$
4. Chia thành $2 \times 2 = 4$ ô con, mỗi ô 4×4 pixel cục bộ
5. Trong mỗi ô: xây dựng histogram 8 bin (45° mỗi bin), trọng số = biên độ gradient
6. Nối 4 histogram: $2 \times 2 \times 8 = 32$ chiều

4.5.3 Chuẩn hoá L2

Vector thô $\mathbf{d} \in \mathbb{R}^{32}$ nhạy với thay đổi độ sáng. Chuẩn hoá:

$$\mathbf{d} \leftarrow \frac{\mathbf{d}}{\|\mathbf{d}\|_2 + \epsilon} \quad (24)$$

với $\epsilon = 10^{-7}$ để tránh chia cho không. Sau chuẩn hoá, nhân độ sáng (tất cả gradient nhân hằng số) không còn ảnh hưởng đến descriptor.

So với SIFT gốc: SIFT gốc dùng lưới $4 \times 4 \times 8 = 128D$, chuẩn hoá L2, cắt tại 0.2, chuẩn hoá L2 lần hai. Phiên bản này dùng $2 \times 2 \times 8 = 32D$ và một lần chuẩn hoá. Nguyên lý hoàn toàn giống nhau — 128 chiều phân biệt tốt hơn nhưng chi phí cao hơn 16 lần.

4.6 Yêu cầu cài đặt

3.1. Scale space và DoG pyramid. Cài đặt hàm xây dựng kim tự tháp: với ảnh đầu vào, $\sigma_0 = 1.6$, $s = 3$ tầng/octave, n_{oct} octave, trả về toàn bộ ảnh Gaussian $L[oct][tng]$ và ảnh DoG $D[oct][tng]$.

3.2. Phát hiện cực trị 26 lân cận. Với mỗi tầng DoG giữa trong mỗi octave, tìm tất cả cực đại và cực tiểu cục bộ trong 26 lân cận. Lọc theo ngưỡng tương phản $\tau_c = 0.03$.

3.3. Gán hướng chủ đạo. Với mỗi keypoint, tính histogram 36 bin theo công thức (22) và xác định θ^* .

3.4. Xây dựng descriptor 32D. Cài đặt theo quy trình sáu bước ở mục 3.4.2. Dùng nearest-neighbor thay vì bilinear interpolation. Chuẩn hoá L2 theo (24).

3.5. Kiểm chứng bất biến.

- (a) *Bất biến góc quay:* tính descriptor của một keypoint trong ảnh gốc và trong ảnh xoay 30° . So sánh hai descriptor bằng khoảng cách Euclid — phải nhỏ hơn đáng kể so với khoảng cách giữa hai keypoint ngẫu nhiên.
- (b) *Bất biến thang đo:* lặp lại với ảnh phóng to $1.5\times$ — số keypoints phát hiện phải tương tự và phân bố ở những vùng tương ứng.